

SAE : Echantillonnage et estimation

Science des Données – Statistique Inférentielle

Nathan MICHONNEAU/ Alix GOURIET



Centre-Val de Loire



INTRODUCTION

L'objectif de cette SAE est d'estimer le nombre d'habitants de la région Centre-Val de Loire à partir d'un échantillon de communes, en quantifiant l'incertitude liée à cette estimation grâce à un intervalle de confiance.

Pour y parvenir, nous allons mettre en place deux méthodes d'échantillonnage différentes. Dans un premier temps, nous travaillerons avec un sondage aléatoire simple, dans lequel chaque commune a la même probabilité d'être tirée.

Dans un second temps, nous adopterons une approche par stratification, qui consiste à diviser la population en groupes homogènes avant d'effectuer le tirage.

Nous terminerons par une comparaison des deux méthodes afin de voir laquelle offre les meilleures estimations.

Echantillonnage aléatoire simple

Avant de commencer l'analyse, les données ont dû être préparées. Le fichier Excel mis à disposition a été converti au format CSV puis importé dans R. Nous avons ensuite sélectionné uniquement les communes de la région Centre-Val de Loire ainsi que les colonnes qui nous intéressaient : le code département, le nom de la commune et la population totale.

Il a aussi été nécessaire de nettoyer la colonne population, qui contenait des espaces non reconnus par R. La fonction `gsub("[^0-9]", ...)` permet de supprimer tout caractère qui n'est pas un chiffre, quel que soit l'encodage de ces espaces. Les lignes sans valeur ont ensuite été retirées.

```
5 # Importation des données
6 # Lecture du fichier CSV (séparateur point-virgule, format français)
7 df <- read.csv2("population_francaise_communes.csv")
8
9 # Sélection des colonnes utiles + filtre sur la région Centre-val de Loire
10 donnees <- df[df["Nom.de.la.région"] == "Centre-Val de Loire",
11               c("Code.département", "Commune", "Population.totale")]
12
13 # Suppression de tous les caractères non numériques (espaces normaux, insécables, etc.)
14 # [^0-9] supprime tout ce qui n'est pas un chiffre, quel que soit l'encodage
15 donnees$Population.totale <- as.numeric(gsub("[^0-9]", "", donnees$Population.totale))
16
17 # Suppression des lignes avec NA dans Population.totale
18 donnees <- donnees[!is.na(donnees$Population.totale), ]
```

La variable U représente l'ensemble des communes de la région Centre-Val de Loire, soit la population mère. La variable T correspond au nombre total d'habitants, soit 2 632 683.

```
23 # Population
24 # U = ensemble des communes de la région (variable de travail pour le tirage)
25 U <- donnees$Commune
26
27 # N = nombre total de communes dans la région
28 N <- length(U)
29 N # Affiche 1757
30
31 # T = nombre exact d'habitants dans la région
32 T <- sum(donnees$Population.totale)
33 T # Affiche 2 632 683
34
35 # Tirage aléatoire simple
36 # Tirage sans remise de n = 100 communes parmi les N communes
37 n <- 100
38 E <- sample(U, n) # Échantillon aléatoire de 100 communes
39 head(E)
```

Un échantillon aléatoire simple de 100 communes est tiré à l'aide de la fonction `sample()`. Les informations correspondant aux communes sélectionnées sont regroupées dans un nouveau data frame, `donnees2`, contenant le nom de la commune et sa population totale.

```
41 # Extraction des données correspondant aux 100 communes tirées
42 donnees1 <- donnees[donnees$Commune %in% E, ]
43
44 # Création d'un sous-tableau avec uniquement commune + population
45 donnees2 <- subset(donnees1, select = c(Commune, Population.totale))
46 head(donnees2)
47
48 # Estimation de la moyenne
49 # Calcul de la moyenne de population sur l'échantillon
50 xbar <- mean(donnees2$Population.totale)
51 xbar # Moyenne des 100 communes tirées
52
53 # Intervalle de confiance à 95% pour la moyenne  $\mu$  (test de student)
54 idcmoy <- t.test(donnees2$Population.totale)$conf.int
55 idcmoy # Borne inf et borne sup de l'IDC pour  $\mu$ 
56
57 # --- Estimation du total T ---
58 # Estimation de la population totale :  $T_{\text{test}} = N * \bar{x}$ 
59 T_test <- N * xbar
60 T_test # Population totale estimée
61
62 # IDC pour le total T = IDC pour  $\mu$  multiplié par N
63 idcT <- idcmoy * N
64 idcT # Intervalle de confiance pour T
65
66 # Marge d'erreur = demi-largeur de l'IDC
67 marge <- (idcT[2] - idcT[1]) / 2
68 marge # Marge d'erreur associée à l'estimation
```

Différents indicateurs ont été calculés à partir de l'échantillon : la moyenne de la population des communes tirées, un intervalle de confiance à 95 % pour estimer la moyenne μ , puis une estimation du total T avec son propre intervalle de confiance.

Pour évaluer la stabilité de cette méthode, le tirage ainsi que les calculs ont été répétés 10 fois. Ces répétitions permettent de constituer un tableau récapitulatif et un graphique illustrant la variabilité des estimations.


```

70 # Répétition 10 fois + export Excel
71 # Tableau pour stocker les résultats des 10 tirages
72 resultats_sas <- data.frame(
73   Population_Totale = numeric(10),
74   Population_estimee = numeric(10),
75   IDC_inf = numeric(10),
76   IDC_sup = numeric(10),
77   Marge_erreur = numeric(10)
78 )
79
80 for (i in 1:10) {
81   # Nouveau tirage aléatoire simple à chaque itération
82   E_i <- sample(U, n)
83   d_i <- donnees[donnees$Commune %in% E_i, ]
84   d2_i <- subset(d_i, select = c(Commune, Population.totale))
85
86   # calcul des indicateurs pour ce tirage
87   xbar_i <- mean(d2_i$Population.totale)
88   idc_i <- t.test(d2_i$Population.totale)$conf.int
89   T_est_i <- N * xbar_i
90   idcT_i <- idc_i * N
91   marge_i <- (idcT_i[2] - idcT_i[1]) / 2
92
93   # Stockage dans le tableau de résultats
94   resultats_sas[i, ] <- c(T, round(T_est_i), round(idcT_i[1]), round(idcT_i[2]), round(marge_i))
95 }
96
97 # Affichage du tableau récapitulatif
98 print(resultats_sas)
99
100 # Export du tableau SAS vers Excel (pour construire le graphique dans Excel)
101 library(writexl)
102 write_xlsx(resultats_sas, "resultats_sas_CVL.xlsx")

```

Population_Totale	Population_estimee	IDC_inf	IDC_sup	Marge_erreur
2632683	2028726	1188409	2869044	840317
2632683	4745710	-155188	9646607	4900897
2632683	2268649	1304153	3233144	964495
2632683	2458197	1335639	3580754	1122557
2632683	2059726	1527393	2592059	532333
2632683	3929272	1155332	6703213	2773941
2632683	4475596	285679	8665513	4189917
2632683	2776617	485718	5067516	2290899
2632683	2060839	1335404	2786275	725436
2632683	2283872	1218426	3349317	1065445

Estimation de la population à l'aide d'un sondage aléatoire simple



Une fois les strates définies, les données sont triées par strate pour faciliter le tirage. On calcule l'effectif total de chaque strate (N_h), ce qui donne la taille totale N et le poids relatif gh de chaque groupe.

Un échantillon de 100 communes est ensuite tiré en respectant une allocation proportionnelle nh est proportionnel au poids de chaque strate. Le tirage est fait avec remise à l'intérieur de chaque strate (méthode srswr). L'objet `data1` contient exactement 100 communes.

Conclusion

La méthode d'échantillonnage aléatoire simple s'est montrée assez imprécise dans notre cas, comme le confirment les résultats obtenus. Les estimations du total de la population étaient régulièrement très éloignées de la valeur réelle, avec parfois des écarts importants dans les deux sens.

Les marges d'erreur étaient également très larges, ce qui illustre bien les limites de cette approche quand elle est utilisée telle quelle. Ces résultats s'expliquent principalement par le fait que la taille des communes n'a pas été prise en compte dans le tirage : une commune de 200 habitants avait autant de chances d'être sélectionnée qu'une ville de 100 000 habitants.

La méthode aléatoire simple n'est donc pas la plus adaptée dans ce contexte, où les unités statistiques sont très hétérogènes en termes de population.

Echantillonnage aléatoire stratifié

Pour améliorer la précision des estimations, nous passons à un échantillonnage stratifié qui tient compte cette fois des différences de taille entre communes. Nous utilisons toujours le même jeu de données sur les communes de Centre-Val de Loire.

```
# Découpe en 4 strates selon les quartiles :  
# Strate 1 : < 272 hab.  
# Strate 2 : 272 à 537 hab.  
# Strate 3 : 537 à 1173 hab.  
# Strate 4 : > 1173 hab.  
# CORRECTION : as.character() évite le bug factor dans strata() (rmultinom)  
donnees$strate <- as.character(cut(donnees$Population.totale,  
                                breaks = c(0, 272, 537, 1173, Inf),  
                                labels = c("1", "2", "3", "4")))
```

Dans un premier temps, la fonction `summary()` est utilisée pour déterminer les quartiles de la variable `Population.totale`. Ces quartiles servent à définir quatre strates correspondant à quatre classes de communes classées par taille croissante.

Cette approche permet de regrouper les communes selon leur taille démographique, ce qui rend l'échantillonnage plus représentatif et réduit les écarts extrêmes observés avec le S.A.S.

```
# Effectif total de chaque strate (Nh)
# factor() avec levels fixes garantit 4 strates même si l'une est vide
Nh <- table(factor(data$strate, levels = c("1", "2", "3", "4")))
Nh

# Taille totale de la population (vérification : doit éгалer N)
N <- sum(Nh)
N

# Poids de chaque strate dans la population (gh = Nh/N)
# as.numeric() supprime les noms du table pour éviter les conflits de dimensions
gh <- as.numeric(Nh) / N
gh

# --- Taille des sous-échantillons (allocation proportionnelle) ---
# nh est proportionnel au poids de chaque strate
n <- 100
nh <- round(as.numeric(Nh) * n / N)
# Ajustement si la somme ne fait pas exactement 100 (problème d'arrondi)
nh[4] <- n - sum(nh[1:3])
nh # Tailles des sous-échantillons par strate

# Taux de sondage dans chaque strate (fh = nh/Nh)
fh <- nh / as.numeric(Nh)
fh

# Tirage stratifié
# Tirage aléatoire AVEC remise (srswr) dans chaque strate
st <- strata(data, stratanames = c("strate"), size = nh, method = "srswr")
data1 <- getdata(data, st) # Récupération de l'échantillon final
head(data1)
length(data1$Commune) # Vérification : doit afficher 100
```

Une fois les strates définies, les données sont triées par strate pour faciliter le tirage. On calcule l'effectif total de chaque strate (Nh), ce qui donne la taille totale N et le poids relatif gh de chaque groupe.

Un échantillon de 100 communes est ensuite tiré en respectant une allocation proportionnelle : nh est proportionnel au poids de chaque strate. Le tirage est fait avec remise à l'intérieur de chaque strate (méthode srswr). L'objet data1 contient exactement 100 communes.

À partir de l'échantillon stratifié, on constitue quatre sous-échantillons correspondant aux quatre strates. Pour chacun, on calcule la moyenne et la variance de la population. Ces valeurs servent à estimer la moyenne globale $\bar{X}_{st}$ en pondérant chaque moyenne par le poids de sa strate.

On calcule également la variance de cette estimation, ce qui permet de construire un intervalle de confiance à 95 % pour μ . En multipliant ensuite par N, on obtient une estimation du total T avec son intervalle de confiance et sa marge d'erreur.

```

# Calcul des estimateurs stratifiés |
# Séparation en 4 sous-échantillons correspondant aux 4 strates
ech1 <- data1[data1$strate == "1", ] # Strate 1 : communes < 272 hab.
ech2 <- data1[data1$strate == "2", ] # Strate 2 : communes 272-537 hab.
ech3 <- data1[data1$strate == "3", ] # Strate 3 : communes 537-1173 hab.
ech4 <- data1[data1$strate == "4", ] # Strate 4 : communes > 1173 hab.

# Moyennes des 4 sous-échantillons (une par strate)
m1 <- mean(ech1$Population.totale)
m2 <- mean(ech2$Population.totale)
m3 <- mean(ech3$Population.totale)
m4 <- mean(ech4$Population.totale)

# Variances des 4 sous-échantillons (variance empirique corrigée)
var1 <- var(ech1$Population.totale)
var2 <- var(ech2$Population.totale)
var3 <- var(ech3$Population.totale)
var4 <- var(ech4$Population.totale)

# Estimation de la moyenne stratifiée  $\bar{X}_{st} = \text{somme}(N_h * m_h) / N$ 
Xbarst <- (Nh[1] * m1 + Nh[2] * m2 + Nh[3] * m3 + Nh[4] * m4) / N

# Estimation de la variance de  $\bar{X}_{st}$  (formule de l'échantillonnage stratifié)
varXbarst <- (gh[1])^2 * (1 - fh[1]) * var1 / nh[1] +
  (gh[2])^2 * (1 - fh[2]) * var2 / nh[2] +
  (gh[3])^2 * (1 - fh[3]) * var3 / nh[3] +
  (gh[4])^2 * (1 - fh[4]) * var4 / nh[4]

# IDC pour  $\mu$  à 95% (loi normale asymptotique)
alpha <- 0.05
binf <- Xbarst - qnorm(1 - alpha / 2) * sqrt(varXbarst) # Borne inférieure
bsup <- Xbarst + qnorm(1 - alpha / 2) * sqrt(varXbarst) # Borne supérieure
idcmoy <- c(binf, bsup)
idcmoy

# Estimation du total T par l'estimateur stratifié
Tstr <- N * Xbarst
Tstr

# IDC pour le total T
binf_T <- idcmoy[1] * N
bsup_T <- idcmoy[2] * N
idcT <- c(binf_T, bsup_T)
idcT

# Marge d'erreur pour le total T
marge <- (idcT[2] - idcT[1]) / 2
marge

```

Pour évaluer la stabilité de la méthode, le tirage stratifié ainsi que les calculs ont été répétés 10 fois. Ces répétitions permettent de constituer un tableau récapitulatif et un graphique illustrant la variabilité des estimations.

```
# Répétition 10 fois + export Excel
resultats_strat <- data.frame(
  Population_Totale = numeric(10),
  Population_estimee = numeric(10),
  IDC_inf = numeric(10),
  IDC_sup = numeric(10),
  Marge_erreur = numeric(10)
)

for (i in 1:10) {
  # Nouveau tirage stratifié à chaque itération
  st_i <- strata(data, stratanames = c("strate"), size = nh, method = "srswr")
  data1_i <- getdata(data, st_i)

  # Séparation en 4 sous-échantillons
  e1_i <- data1_i[data1_i$strate == "1", ]
  e2_i <- data1_i[data1_i$strate == "2", ]
  e3_i <- data1_i[data1_i$strate == "3", ]
  e4_i <- data1_i[data1_i$strate == "4", ]

  # Moyennes et variances par strate
  m_i <- c(mean(e1_i$Population.totale), mean(e2_i$Population.totale),
           mean(e3_i$Population.totale), mean(e4_i$Population.totale))
  var_i <- c(var(e1_i$Population.totale), var(e2_i$Population.totale),
            var(e3_i$Population.totale), var(e4_i$Population.totale))


  # Moyenne stratifiée et sa variance
  Xb_i <- sum(as.numeric(Nh) * m_i) / N
  vXb_i <- sum(gh^2 * (1 - fh) * var_i / nh)

  # IDC et marge d'erreur pour T
  b1_i <- (Xb_i - qnorm(0.975) * sqrt(vXb_i)) * N
  b2_i <- (Xb_i + qnorm(0.975) * sqrt(vXb_i)) * N
  resultats_strat[i, ] <- c(T, round(N * Xb_i), round(b1_i), round(b2_i), round((b2_i - b1_i) / 2))
}

print(resultats_strat)

# Export du tableau stratifié vers Excel
write_xlsx(resultats_strat, "resultats_stratifie_CVL.xlsx")
# --> Ouvrir ce fichier Excel pour créer le graphique des estimations stratifiées
```


Estimation de la population à l'aide d'un échantillonnage aléatoire stratifié



Les résultats obtenus avec la méthode stratifiée sont bien meilleurs que ceux du S.A.S. En répartissant les communes en quatre strates selon leur population, on représente mieux la diversité démographique de la région. Les estimations se rapprochent davantage de la valeur réelle et les marges d'erreur sont plus faibles.

La comparaison des deux méthodes montre clairement que l'échantillonnage stratifié est plus adapté ici. Il limite les biais dus aux communes très peuplées ou très peu peuplées et améliore la précision des intervalles de confiance. Pour aller plus loin, on pourrait augmenter le nombre de strates ou utiliser une allocation de Neyman plutôt que proportionnelle.

Au cours de cette partie, nous avons appris à mettre en place deux méthodes d'échantillonnage et à comparer leurs résultats. Cela nous a permis de mieux comprendre l'importance du choix méthodologique dans un sondage et d'acquérir des compétences en programmation R.

Echantillonnage aléatoire stratifié

Dans cette partie, l'objectif est de repérer des liens significatifs entre la variable sport et d'autres variables qualitatives de l'enquête. Pour cela, le fichier CSV a été importé dans R et analysé.

PARTIE 2 : TRAITEMENT DE DONNEES D'ENQUETE

```
# Chargement du fichier d'enquête (séparateur point-virgule)
donnees_enq <- read.csv2("EnqueteSportEtudiant2024.csv")
```

```
# Affichage des 6 premières lignes
```

```
head(donnees_enq)
```

```
# 375 individus, 76 variables qualitatives
```

Le jeu de données contient 375 individus et 76 variables, toutes qualitatives. On remarque que certains étudiants n'ont pas répondu à toutes les questions, ce qui limite le choix des variables à croiser avec sport.

Nous avons retenu les variables suivantes : sexe, département géographique, département de formation, statut fumeur, état de santé, alimentation et réussite. Ces variables sont toutes complètes et liées au mode de vie, ce qui les rend pertinentes pour expliquer la pratique sportive.

```
# Tableau croisé sport x sexe
```

```
TCD_sexe <- table(donnees_enq$sport, donnees_enq$sexe)
```

```
TCD_sexe
```

```
# Tableau croisé sport x département géographique
```

```
TCD_deptgeo <- table(donnees_enq$sport, donnees_enq$deptgeo)
```

```
# Tableau croisé sport x département de formation
```

```
TCD_deptform <- table(donnees_enq$sport, donnees_enq$deptformation)
```

```
# Tableau croisé sport x statut fumeur
```

```
TCD_fumer <- table(donnees_enq$sport, donnees_enq$fumer)
```

```
# Tableau croisé sport x état de santé
```

```
TCD_sante <- table(donnees_enq$sport, donnees_enq$sante)
```

```
# Tableau croisé sport x alimentation
```

```
TCD_alim <- table(donnees_enq$sport, donnees_enq$alimentation)
```

```
# Tableau croisé sport x réussite
```

```
TCD_reussite <- table(donnees_enq$sport, donnees_enq$reussite)
```

```
# --- Tests du Khi-deux ---
```

```
# Test d'indépendance entre sport et chaque variable choisie
```

```
khideux_sexe <- chisq.test(TCD_sexe)
```

```
khideux_deptgeo <- chisq.test(TCD_deptgeo)
```

```
khideux_deptform <- chisq.test(TCD_deptform)
```

```
khideux_fumer <- chisq.test(TCD_fumer)
```

```
khideux_sante <- chisq.test(TCD_sante)
```

```
khideux_alim <- chisq.test(TCD_alim)
```

```
khideux_reussite <- chisq.test(TCD_reussite)
```

```
# Récapitulatif des p-valeurs
p_valeurs <- c(
  Sexe = khideux_sexe$p.value,
  Deptgeo = khideux_deptgeo$p.value,
  Deptformation = khideux_deptform$p.value,
  Fumer = khideux_fumer$p.value,
  Sante = khideux_sante$p.value,
  Alimentation = khideux_alim$p.value,
  Reussite = khideux_reussite$p.value
)
print(round(p_valeurs, 4))
# Les p-valeurs < 0.01 indiquent une relation significative avec "sport"
```

Pour chaque variable retenue, un test du khi-deux a été réalisé afin de calculer la p-valeur. Les p-valeurs inférieures à 0,01 indiquent une relation significative avec sport. Le V de Cramer a ensuite été calculé pour mesurer la force de ces liaisons.

```
# V de Cramer pour les variables significatives (p < 0.01)
# Formule :  $V = \sqrt{\text{Chi}^2 / (n * (\min(r,c) - 1))}$ 
# Calcul du V de Cramer pour les variables significatives
library(vcd) # Contient la fonction assocstats()

# Fonction utilitaire pour calculer le V de Cramer manuellement
v_cramer <- function(tableau_croise) {
  chi2 <- chisq.test(tableau_croise)$statistic # Statistique  $\text{Chi}^2$ 
  n <- sum(tableau_croise) # Effectif total
  k <- min(nrow(tableau_croise), ncol(tableau_croise)) # Min(nb lignes, nb colonnes)
  V <- sqrt(chi2 / (n * (k - 1))) # Formule du V de Cramer
  return(as.numeric(V))
}

v_sexe <- v_cramer(TCD_sexe)
v_deptform <- v_cramer(TCD_deptform)
v_alim <- v_cramer(TCD_alim)

# Tableau récapitulatif final (Chi-deux, p-valeur, V de Cramer)
recap <- data.frame(
  Variable = c("Sexe", "Deptgeo", "Deptformation", "Fumer", "Sante", "Alimentation", "Reussite"),
  Chi2_obs = round(c(khideux_sexe$statistic, khideux_deptgeo$statistic,
    khideux_deptform$statistic, khideux_fumer$statistic,
    khideux_sante$statistic, khideux_alim$statistic,
    khideux_reussite$statistic), 4),
  p_valeur = round(p_valeurs, 6),
  V_de_Cramer = c(v_sexe, NA, v_deptform, NA, NA, v_cramer(TCD_alim), NA)
)
print(recap)
# La relation la plus forte est indiquée par le V de Cramer le plus élevé
```

Variable	Chi² obs.	p-valeur	Significatif $\alpha=1\%$	V de Cramer
Sexe	12.47	0.0021	Oui	0.183
Deptgeo	8.23	0.0831	Non	—
Deptformation	18.92	< 0.001	Oui	0.225
Fumer	3.10	0.2119	Non	—
Santé	6.87	0.1430	Non	—
Alimentation	22.51	< 0.001	Oui	0.245
Réussite	5.11	0.2771	Non	—

La relation la plus marquée concerne l'alimentation, avec un V de Cramer de 0,245. Cela veut dire que les étudiants qui font attention à leur alimentation ont tendance à pratiquer davantage un sport.

L'analyse montre que certains aspects du mode de vie sont bien liés à la pratique sportive. L'alimentation ressort comme le facteur le plus associé, devant le département de formation et le sexe. Les autres variables testées ne présentent pas de lien significatif avec sport dans cet échantillon.

Conclusion :

Cette SAE nous a permis de mettre en pratique deux méthodes d'échantillonnage sur les communes de la région Centre-Val de Loire. La méthode aléatoire simple, facile à mettre en place, produit des estimations trop variables et peu fiables dans ce contexte. L'échantillonnage stratifié, en tenant compte de la structure de la population, améliore nettement la précision des résultats.

Cette comparaison nous a aidés à développer un regard critique sur les choix méthodologiques en sondage et à renforcer nos compétences en programmation R.

Sur la partie enquête, les tests du khi-deux et le V de Cramer ont mis en évidence des liens significatifs entre la pratique sportive et plusieurs variables liées au mode de vie des étudiants, notamment l'alimentation.